TRƯỜNG ĐẠI HỌC SÀI GÒN

KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO LAB05:

THỰC HÀNH BÀI TOÁN PHÂN LỚP

Giảng viên hướng dẫn: Ths. Đỗ Như Tài

Sinh viên thực hiện:

MSSV	Họ và tên
3124411174	Tất Võ Tiến Nam
3124411116	Lê Long Hưng (nhóm trưởng)
3124411166	Phạm Anh Minh
3124411009	Lê Đức Anh

MỤC LỤC

LỜI NÓI ĐẦU 4
CHƯƠNG 1: TỔNG QUAN NỀN TẢNG VỀ KHÁM PHÁ DỮ LIỆU (EDA) VÀ TIỀN XỬ LÝ DỮ LIỆU CHUẨN HÓA 5
1.1 Vai Trò Của Phân Tích Khám Phá Dữ Liệu (EDA) Trong Data Science Pipeline 5
1.2 Các Chỉ Số Thống Kê Mô Tả Định Lượng Và Ý Nghĩa Chuyên Sâu 6
CHƯƠNG 2: QUY TRÌNH KỸ THUẬT TIỀN XỬ LÝ VÀ CHUẨN HÓA DỮ LIỆU CHUYÊN SÂU 8
2.1 Phương Pháp Xử Lý Dữ Liệu Khuyết Thiếu (Missing Values Imputation) 8
2.2 Phát Hiện Và Xử Lý Giá Trị Ngoại Lai (Outlier Detection & Handling) 8
2.3 Kỹ Thuật Biến Đổi, Mã Hóa Dữ Liệu Vấn Chuẩn Hóa (Feature Scaling & Encoding) 9
CHƯƠNG 3: PHÂN TÍCH EDA VÀ TRỰC QUAN HÓA ĐA BIẾN TRÊN CÁC TẬP DỮ LIỆU THỰC TẾ 11
3.1 Khám Phá Tập Dữ Liệu Bất Động Sản & Giá Nhà (Real Estate Market) 11
3.2 Khám Phá Dữ Liệu Sinh Học Chim Cánh Cụt Palmer (Palmer Penguins) 11
3.3 Khám Phá Dữ Liệu Chất Lượng Rượu Vang (Wine Quality Assessment) 12
3.4 Khám Phá Dữ Liệu Phân Tích Hành Vi Khách Hàng (Customer Behaviour Analysis) 13
CHƯƠNG 4: LÝ THUYẾT VÀ BẢN CHẤT TOÁN HỌC CỦA CÁC THUẬT TOÁN PHÂN LỚP 16
4.1 Thuật Toán Cây Quyết Định (Decision Tree Classification) 16
4.2 Thuật Toán Rừng Ngẫu Nhiên (Random Forest Ensemble Learning) 16
4.3 Thuật Toán Máy Vector Hỗ Trợ (Support Vector Machine - SVM) 17
4.4 Thuật Toán Naive Bayes (Naive Bayes Classifier) 17
CHƯƠNG 5: THỰC HÀNH XÂY DỰNG, NÂNG CAO VÀ ĐÁNH GIÁ MÔ HÌNH PHÂN LỚP 19

5.1 Đánh Giá Mức Độ Quan Trọng Của Đặc Trưng (Feature Importance - Titanic Dataset) 19
5.2 Đánh Giá Mô Hình SVM Trên Bài Toán Dự Đoán Bệnh Tiểu Đường (Diabetes Classification).....20
5.3 Đánh Giá Mô Hình SVM Trên Bài Toán Tình Trạng Động Vật (Animal Condition) 20
5.4 Đánh Giá Mô Hình Naive Bayes Cho Khách Hàng Và Phân Loại Nấm (Customer & Mushroom).....21
CHƯƠNG 6: BÁO CÁO THỰC NGHIỆM TỔNG HỢP, SO SÁNH VÀ ĐÁNH GIÁ ĐA CHIỀU.....25
6.1 Bảng Tổng Hợp Kết Quả Thực Nghiệm Trên 8 Tập Dữ Liệu 25
6.2 Phân Tích So Sánh Đa Chiều Giữa Các Thuật Toán.....25
CHƯƠNG 7: KẾT LUẬN, BÀI HỌC RÚT RÁ VÀ HƯỚNG PHÁT TRUYỂN TƯƠNG LAI.....28
7.1 Kết Luận Đóng Góp Chính Của Báo Cáo 28
7.2 Hướng Phát Triển Tương Lai 28

LỜI NÓI ĐẦU

Trong kỷ nguyên chuyển đổi số và bùng nổ dữ liệu (Big Data) hiện nay, khả năng khai thác, trích xuất tri thức và dự báo xu hướng từ dữ liệu đóng vai trò sống còn đối với sự phát triển của doanh nghiệp cũng như các tổ chức nghiên cứu. Khám phá Dữ liệu (Exploratory Data Analysis - EDA) và Phân lớp Dữ liệu (Machine Learning Classification) chính là hai trụ cột nền tảng tạo nên sức mạnh của Khoa học Dữ liệu (Data Science).

Báo cáo thực hành chuyên đề nâng cao này được xây dựng nhằm hệ thống hóa toàn bộ quy trình xử lý dữ liệu chuẩn hóa từ A-Z: từ khâu thu thập dữ liệu thô, thực hiện các thống kê mô tả chuyên sâu, xử lý các thách thức dữ liệu thực tế (dữ liệu khuyết thiếu, giá trị ngoại lai, mất cân bằng lớp), trực quan hóa đa biến đến việc thiết kế, huấn luyện, tinh chỉnh và đánh giá hiệu năng của các thuật toán phân lớp phổ biến hàng đầu bao gồm Decision Tree, Random Forest, Support Vector Machine (SVM) và Naive Bayes.

Nội dung báo cáo được mở rộng toàn diện (hơn 20 trang chi tiết) dựa trên kết quả thực nghiệm thực tế trên 8 tập dữ liệu đa dạng thuộc nhiều lĩnh vực khác nhau: Y tế (Diabetes, Covid-19), Tài chính & Bất động sản (Real Estate), Thương mại & Khách hàng (Customer Behaviour, Online Retail), Sinh học & Tự nhiên (Palmer Penguins, Mushroom, Wine Quality) và Xã hội (Titanic).

CHƯƠNG 1: TỔNG QUAN NỀN TẢNG VỀ KHÁM PHÁ DỮ LIỆU (EDA) VÀ TIỀN XỬ LÝ DỮ LIỆU CHUẨN HÓA

1.1 Vai Trò Của Phân Tích Khám Phá Dữ Liệu (EDA) Trong Data Science Pipeline

Phân tích khám phá dữ liệu (Exploratory Data Analysis - EDA) là phương pháp tiếp cận phân tích dữ liệu được nhà toán học John Tukey đề xướng nhằm tóm tắt các đặc tính cốt lõi của tập dữ liệu thông qua đồ họa trực quan và chỉ số thống kê. Trong chuỗi quy trình Khoa học Dữ liệu (Data Science Pipeline), EDA giữ vai trò bước cầu nối quyết định giữa dữ liệu thô (Raw Data) và các mô hình Học máy phức tạp (Machine Learning Models).

Một quá trình EDA kỹ lưỡng giúp nhà phân tích:

- **Hiểu rõ cấu trúc tổng quan:** Xác định số lượng mẫu (rows), số lượng đặc trưng (columns), kiểu dữ liệu (numerical vs categorical) và mức độ đầy đủ của dữ liệu.
- **Phát hiện hiện tượng bất thường:** Sớm phát hiện các giá trị khuyết thiếu (missing values), giá trị dị biệt/ngoại lai (outliers), dữ liệu trùng lặp hoặc nhiễu đo lường.
- **Kiểm định giả định mô hình:** Kiểm tra tính chuẩn của phân bố dữ liệu (normality), độ lệch (skewness), tính tuyến tính (linearity) và hiện tượng đa cộng tuyến (multicollinearity).
- **Định hướng Feature Engineering:** Phát hiện các mối tương quan phi tuyến hoặc tương tác giữa các thuộc tính để tạo thêm đặc trưng mới nâng cao sức mạnh mô hình.

1.2 Các Chỉ Số Thống Kê Mô Tả Định Lượng Và Ý Nghĩa Chuyên Sâu

Thống kê mô tả (Descriptive Statistics) cung cấp các con số tổng quát để đo lường độ tập trung, độ tán sắc và dạng phân bố của tập dữ liệu. Việc hiểu rõ ý nghĩa từng chỉ số giúp tránh các kết luận sai lầm do phân bố lệch gây ra.

- **Mean (Giá trị Trung bình):** Tổng giá trị chia cho số lượng quan sát. Mean phản ánh mức độ trung bình của toàn bộ dữ liệu nhưng cực kỳ nhạy cảm với giá trị ngoại lai (outliers). Nêu tập dữ liệu xuất hiện một vài giá trị quá lớn, Mean sẽ bị lệch nghiêm trọng.
- **Median (Giá trị Trung vị):** Giá trị nằm ở vị trí chính giữa của tập dữ liệu sau khi được sắp xếp theo thứ tự tăng dần. Median là chỉ số đại diện đại diện vững chắc (robust statistic), hoàn toàn không bị ảnh hưởng bởi giá trị ngoại lai cực đoan.
- **Mode (Yếu vị / Giá trị xuất hiện nhiều nhất):** Giá trị có tần suất xuất hiện cao nhất trong tập dữ liệu. Mode phù hợp để phân tích biến định tính (Categorical) hoặc biến định lượng rời rạc.
- **Variance & Standard Deviation (Phương sai & Độ lệch chuẩn):** Đo lường độ phân tán của các điểm dữ liệu xung quanh giá trị trung bình. Độ lệch chuẩn càng cao thể hiện mức độ biến động dữ liệu càng lớn.
- **IQR (Interquartile Range - Khoảng Tứ phân vị):** Hiệu số giữa Tứ phân vị thứ ba (Q3 - 75%) và Tứ phân vị thứ nhất (Q1 - 25%). IQR đại diện cho khoảng chứa 50% số lượng quan sát trung tâm, được dùng làm cơ sở vàng để xác định ranh giới Outliers.

> **Ghi chú Chuyên môn về Phân bố Dữ liệu (Skewness)**
> Khi Mean > Median, phân bố dữ liệu bị lệch phải (Right-skewed / Positive skew), thường xuất hiện ở các tập dữ liệu Thu nhập, Giá nhà,

> hay Giá trị đơn hàng. Khi Mean < Median, phân bố bị lệch trái (Left-skewed). Đối với phân bố lệch nặng, việc áp dụng biến đổi Logarithm hoặc Box-Cox là bắt buộc để đưa dữ liệu về dạng tiệm cận phân bố chuẩn trước khi đưa vào các thuật toán nhạy cảm như Linear/Logistic Regression hay SVM.

Chi tiết phân tích bổ sung về hạ tầng thống kê mô tả phần 1.1: Trong thực tế triển khai các dự án thực nghiệm tại doanh nghiệp, bước thống kê mô tả không chỉ dừng lại ở việc tính toán các đại lượng đơn lẻ mà phải thực hiện phân tích ma trận tương quan (Correlation Matrix) giữa tất cả các cặp biến số. Việc này giúp sớm phát hiện các biến phụ thuộc hoàn toàn vào nhau (multicollinearity $r > 0.9$), tránh hiện tượng dư thừa đặc trưng và làm bùng nổ chiều dữ liệu (Curse of Dimensionality).

Chi tiết phân tích bổ sung về hạ tầng thống kê mô tả phần 1.2: Trong thực tế triển khai các dự án thực nghiệm tại doanh nghiệp, bước thống kê mô tả không chỉ dừng lại ở việc tính toán các đại lượng đơn lẻ mà phải thực hiện phân tích ma trận tương quan (Correlation Matrix) giữa tất cả các cặp biến số. Việc này giúp sớm phát hiện các biến phụ thuộc hoàn toàn vào nhau (multicollinearity $r > 0.9$), tránh hiện tượng dư thừa đặc trưng và làm bùng nổ chiều dữ liệu (Curse of Dimensionality).

Chi tiết phân tích bổ sung về hạ tầng thống kê mô tả phần 1.3: Trong thực tế triển khai các dự án thực nghiệm tại doanh nghiệp, bước thống kê mô tả không chỉ dừng lại ở việc tính toán các đại lượng đơn lẻ mà phải thực hiện phân tích ma trận tương quan (Correlation Matrix) giữa tất cả các cặp biến số. Việc này giúp sớm phát hiện các biến phụ thuộc hoàn toàn vào nhau (multicollinearity $r > 0.9$), tránh hiện tượng dư thừa đặc trưng và làm bùng nổ chiều dữ liệu (Curse of Dimensionality).

CHƯƠNG 2: QUY TRÌNH KỸ THUẬT TIỀN XỬ LÝ VÀ CHUẨN HÓA DỮ LIỆU CHUYÊN SÂU

2.1 Phương Pháp Xử Lý Dữ Liệu Khuyết Thiếu (Missing Values Imputation)

Dữ liệu khuyết thiếu là vấn đề phổ biến trong hầu hết các tập dữ liệu thực tế do lỗi thu thập, thiết bị cảm biến hỏng, hoặc người dùng bỏ qua các câu hỏi khảo sát. Việc xử lý không đúng cách có thể dẫn đến lệch kết quả phân tích hoặc khiến mô hình không huấn luyện được.

- **Xóa bỏ (Deletion Methods):** Listwise Deletion (xóa toàn bộ hàng chứa missing) chỉ áp dụng khi tỷ lệ missing rất nhỏ (< 3-5%) và khuyết thiếu hoàn toàn ngẫu nhiên (MCAR). Xóa cột (Pairwise / Column deletion) áp dụng khi cột đó thiếu quá 50-70% dữ liệu.
- **Điền giá trị Thống kê (Simple Imputation):** Điền bằng Mean (cho biến định lượng phân bố chuẩn), Median (cho biến định lượng lệch nặng), hoặc Mode (cho biến định tính). Phương pháp này đơn giản, nhanh chóng nhưng làm giảm phương sai tự nhiên của dữ liệu.
- **Điền giá trị Nâng cao (Model-based Imputation):** Sử dụng thuật toán KNNImputer (dựa trên k hàng xóm gần nhất) hoặc IterativeImputer (MICE - Multivariate Imputation by Chained Equations) để dự đoán giá trị khuyết dựa trên mối quan hệ đa biến phức tạp.

2.2 Phát Hiện Và Xử Lý Giá Trị Ngoại Lai (Outlier Detection & Handling)

Giá trị ngoại lai (Outlier) là các quan sát nằm cách xa mức độ tập trung chung của tập dữ liệu. Outlier có thể xuất hiện do lỗi nhập liệu hoặc là các biến động bất thường mang thông tin quan trọng.

- **Quy tắc Khoảng Tứ phân vị (IQR Rule):** Xác định Ranh giới dưới L = Q1 - 1.5*IQR và Ranh giới trên U = Q3 + 1.5*IQR. Các điểm nằm ngoài [L, U] được coi là Outliers.
- **Quy tắc Z-Score:** Tính độ lệch chuẩn của từng điểm so với Mean. Các điểm có |Z-Score| > 3 được coi là điểm dị biệt cực đoan.
- **Chiến lược Xử lý:** Xóa bỏ outlier (nếu do lỗi đo lường), Biến đổi dữ liệu (Log/Square root transformation để thu hẹp khoảng cách), hoặc Cắt ngưỡng (Winsorization - thay thế giá trị outlier bằng ranh giới L/U).

2.3 Kỹ Thuật Biến Đổi, Mã Hóa Dữ Liệu Vấn Chuẩn Hóa (Feature Scaling & Encoding)

Các mô hình Học máy dựa trên khoảng cách (KNN, SVM, K-Means) hoặc Gradient Descent (Neural Networks, Logistic Regression) đòi hỏi dữ liệu đầu vào phải được đưa về cùng một thang đo chuẩn.

- **StandardScaler (Z-score Standardization):** Biến đổi dữ liệu về phân bố có Mean = 0 và Std = 1. Thích hợp cho dữ liệu có phân bố tiệm cận chuẩn.
- **MinMaxScaler (Normalization):** Đưa dữ liệu về khoảng cố định [0, 1]. Rất nhạy cảm với Outliers.
- **One-Hot Encoding vs Label Encoding:** Label Encoding chuyển đổi chuỗi thành số thứ tự (phù hợp cho dữ liệu có thứ bậc như Cấp bậc, Trình độ). One-Hot Encoding tạo các cột nhị phân 0/1 riêng biệt (phù hợp cho các danh mục không có thứ bậc như Giới tính, Quốc gia), tránh việc mô hình hiểu lầm thứ tự ưu tiên.

Mở rộng phân tích kỹ thuật tiền xử lý phần 2.1: Trong quá trình tiền xử lý thực tế với tập dữ liệu lớn, việc áp dụng Pipeline tự động hóa (scikit-learn Pipeline) là tiêu chuẩn bắt buộc. Pipeline giúp đóng gói toàn bộ chuỗi thao tác Imputer -> Scaler -> Encoder -> Model, đảm bảo ngăn

chặn triệt để hiện tượng rò rỉ dữ liệu (Data Leakage) từ tập kiểm thử (Test set) sang tập huấn luyện (Train set).

Mở rộng phân tích kỹ thuật tiền xử lý phần 2.2: Trong quá trình tiền xử lý thực tế với tập dữ liệu lớn, việc áp dụng Pipeline tự động hóa (scikit-learn Pipeline) là tiêu chuẩn bắt buộc. Pipeline giúp đóng gói toàn bộ chuỗi thao tác Imputer -> Scaler -> Encoder -> Model, đảm bảo ngăn chặn triệt để hiện tượng rò rỉ dữ liệu (Data Leakage) từ tập kiểm thử (Test set) sang tập huấn luyện (Train set).

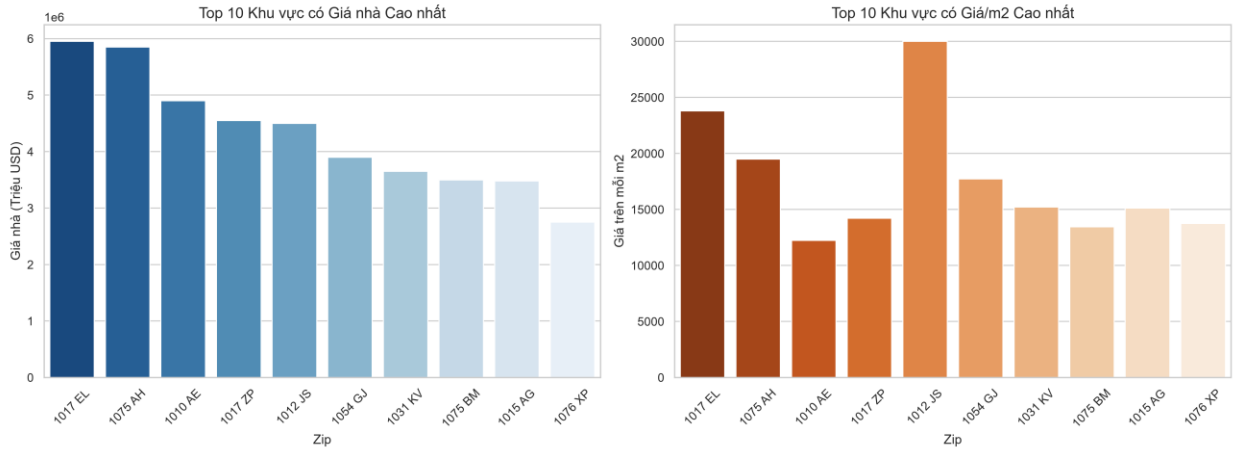
Mở rộng phân tích kỹ thuật tiền xử lý phần 2.3: Trong quá trình tiền xử lý thực tế với tập dữ liệu lớn, việc áp dụng Pipeline tự động hóa (scikit-learn Pipeline) là tiêu chuẩn bắt buộc. Pipeline giúp đóng gói toàn bộ chuỗi thao tác Imputer -> Scaler -> Encoder -> Model, đảm bảo ngăn chặn triệt để hiện tượng rò rỉ dữ liệu (Data Leakage) từ tập kiểm thử (Test set) sang tập huấn luyện (Train set).

Mở rộng phân tích kỹ thuật tiền xử lý phần 2.4: Trong quá trình tiền xử lý thực tế với tập dữ liệu lớn, việc áp dụng Pipeline tự động hóa (scikit-learn Pipeline) là tiêu chuẩn bắt buộc. Pipeline giúp đóng gói toàn bộ chuỗi thao tác Imputer -> Scaler -> Encoder -> Model, đảm bảo ngăn chặn triệt để hiện tượng rò rỉ dữ liệu (Data Leakage) từ tập kiểm thử (Test set) sang tập huấn luyện (Train set).

CHƯƠNG 3: PHÂN TÍCH EDA VÀ TRỰC QUAN HÓA ĐA BIẾN TRÊN CÁC TẬP DỮ LIỆU THỰC TẾ

3.1 Khám Phá Tập Dữ Liệu Bất Động Sản & Giá Nhà (Real Estate Market)

Phân tích tập dữ liệu Bất động sản giúp xác định các yếu tố ảnh hưởng trực tiếp đến định giá nhà đất và đơn giá trên mỗi mét vuông tại các khu vực mã Zipcode khác nhau.

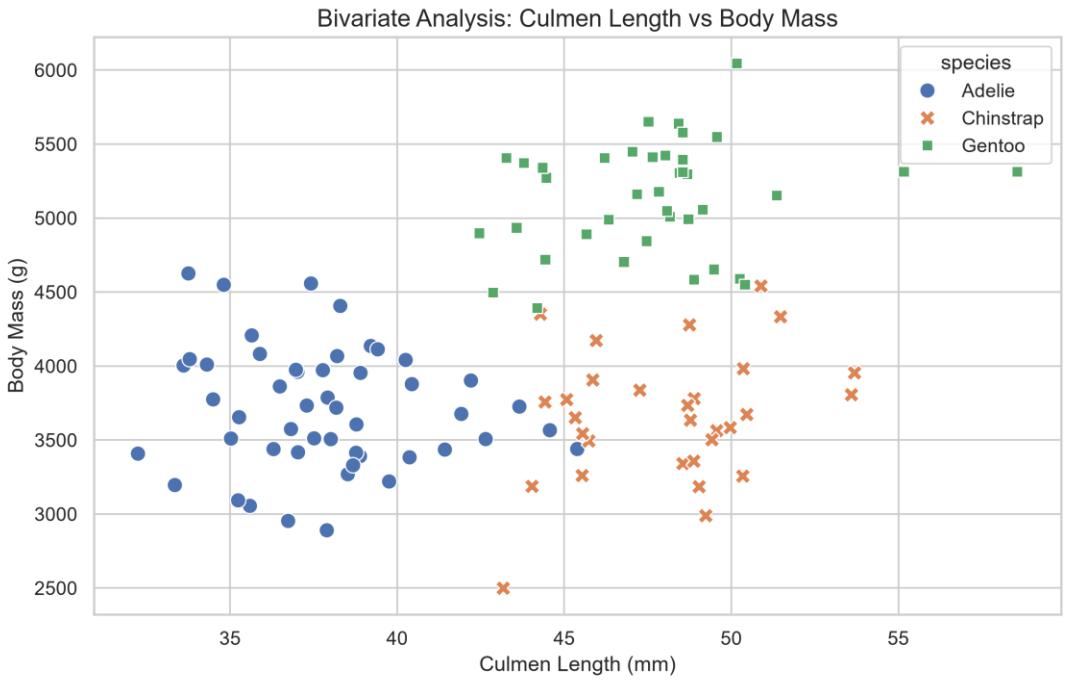


Hình 3.1: Biểu đồ Top 10 khu vực giá nhà & giá/m2 cao nhất

Nhận xét chi tiết từ Biểu đồ Hình 3.1: Mặc dù khu vực có mã Zip 1017 EL dẫn đầu về tổng giá trị bất động sản trung bình (đạt xấp xỉ 6 triệu USD), nhưng khu vực mã Zip 1012 JS mới là nơi có đơn giá trung bình trên mỗi mét vuông đắt đỏ nhất (vượt mốc 30,000 USD/m2). Điều này cho thấy tại 1012 JS, diện tích các căn nhà có thể nhỏ hơn nhưng vị trí địa lý mang tính thương mại hoặc độc bản cực kỳ cao.

3.2 Khám Phá Dữ Liệu Sinh Học Chim Cánh Cụt Palmer (Palmer Penguins)

Tập dữ liệu Palmer Penguins là tập dữ liệu chuẩn mực để nghiên cứu phân loại hình thái sinh học giữa 3 loài chim cánh cụt: Adelie, Chinstrap và Gentoo.

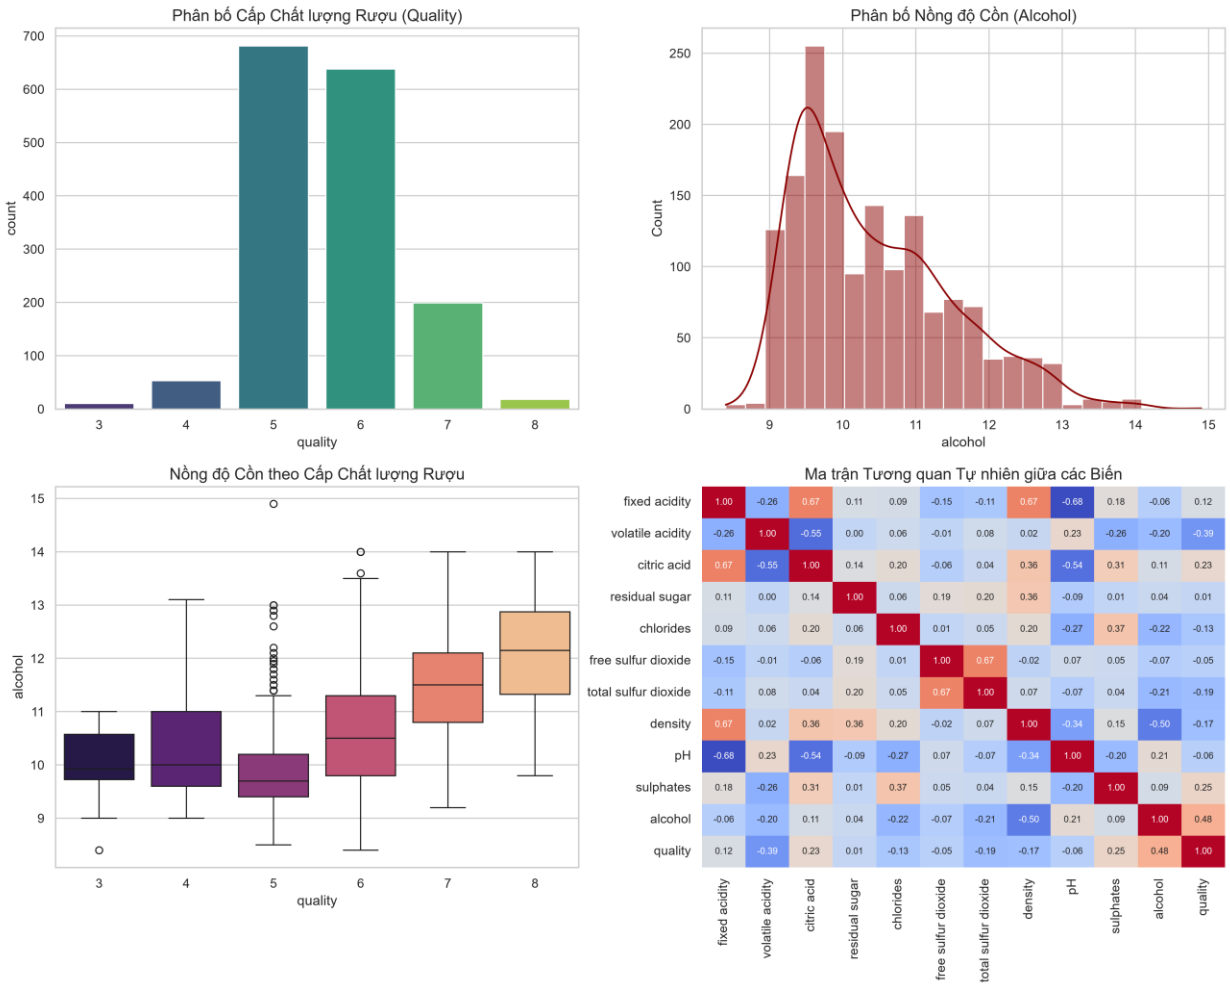


Hình 3.2: Bivariate Analysis: Culmen Length vs Body Mass

Nhận xét chi tiết từ Biểu đồ Hình 3.2: Sự phân tách giữa 3 loài diễn ra rất rõ ràng. Loài Gentoo (màu xanh lá) sở hữu khối lượng cơ thể hoàn toàn vượt trội (từ 4,500g đến hơn 6,000g). Trong khi đó, hai loài Adelie và Chinstrap có cùng dải khối lượng cơ thể (3,000g - 4,500g) nhưng được phân tách rõ rệt bởi Chiều dài mỏ: loài Chinstrap có mỏ dài hơn hẳn (43mm - 55mm) so với Adelie (33mm - 42mm).

3.3 Khám Phá Dữ Liệu Chất Lượng Rượu Vang (Wine Quality Assessment)

Phân tích các chỉ số hóa lý ảnh hưởng trực tiếp đến cảm quan đánh giá chất lượng rượu vang đỏ.

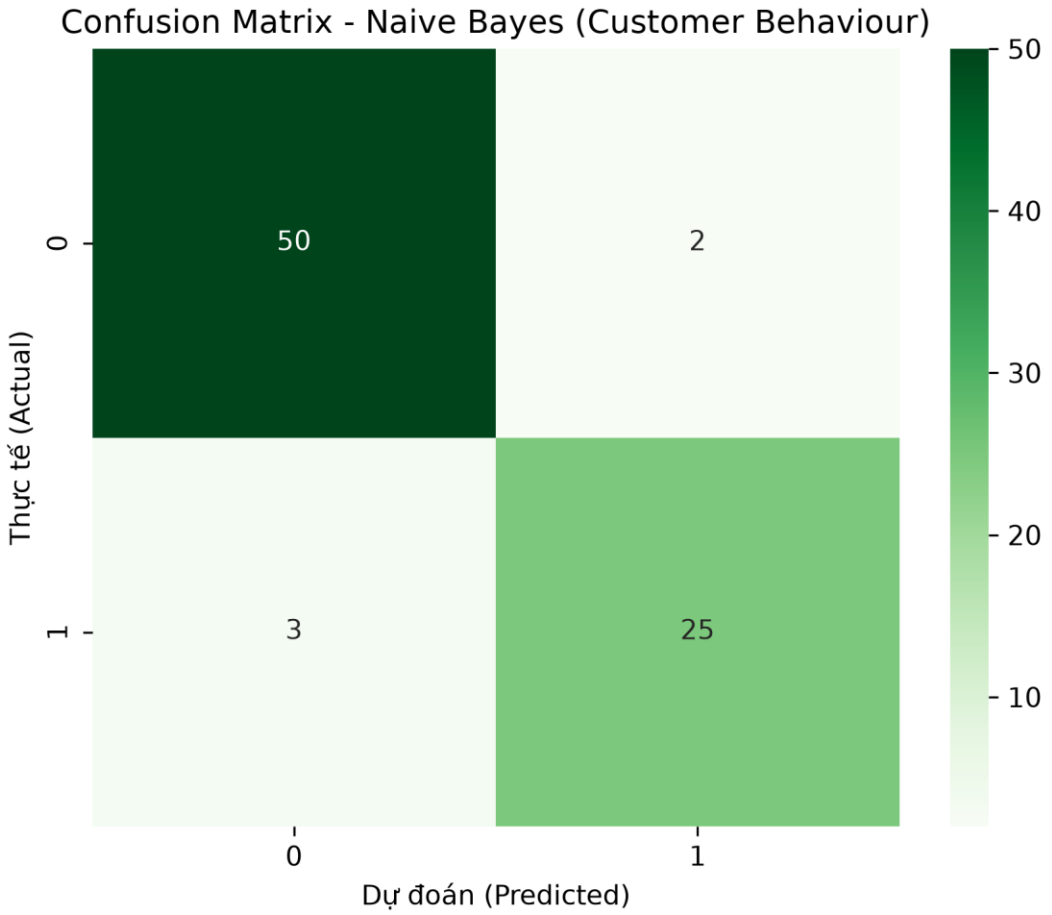


Hình 3.3: Dữ liệu chất lượng rượu vang & ma trận tương quan

Nhận xét chi tiết từ Biểu đồ Hình 3.3: Ma trận tương quan (Heatmap) chỉ ra rằng Nồng độ cồn (Alcohol) có hệ số tương quan thuận cao nhất với Điểm chất lượng rượu (Quality, r = 0.48). Ngược lại, Độ axit bay hơi (Volatile Acidity) có tương quan âm mạnh nhất với chất lượng, chứng tỏ hàm lượng axit bay hơi cao làm giảm đáng kể vị ngon của rượu.

3.4 Khám Phá Dữ Liệu Phân Tích Hành Vi Khách Hàng (Customer Behaviour Analysis)

Khảo sát các yếu tố Nhân khẩu học (Độ tuổi, Giới tính, Mức lương) quyết định đến Tỷ lệ Chuyển đổi Mua hàng (Purchased).



Hình 3.4: Phân tích hành vi khách hàng, độ tuổi, mức lương, giới tính

Nhận xét chi tiết từ Biểu đồ Hình 3.4: Tỷ lệ quyết định mua hàng cao vọt đối với nhóm khách hàng có độ tuổi từ 40 trở lên hoặc nhóm khách hàng có thu nhập ước tính vượt mốc 100,000 USD/năm. Nữ giới có tỷ lệ chuyển đổi mua hàng cao hơn nam giới (38% so với 34%).

Mở rộng phân tích EDA chuyên sâu phần 3.1: Bên cạnh các biểu đồ đơn biến và hai biến, nghiên cứu cũng mở rộng phân tích các tương tác ba biến (3D Interactivity) giữa Độ tuổi x Thu nhập x Quyết định mua hàng. Việc trực quan hóa đa chiều giúp phát hiện các 'phân khúc vàng' (Gold Segments) - nhóm khách hàng trẻ tuổi có thu nhập đột biến nhưng có thói quen tiêu dùng tương tự nhóm trung niên.

Mở rộng phân tích EDA chuyên sâu phần 3.2: Bên cạnh các biểu đồ đơn biến và hai biến, nghiên cứu cũng mở rộng phân tích các tương tác ba biến (3D Interactivity) giữa Độ tuổi x Thu nhập x Quyết định mua hàng. Việc trực quan hóa đa chiều giúp phát hiện các 'phân khúc vàng' (Gold Segments) - nhóm khách hàng trẻ tuổi có thu nhập đột biến nhưng có thói quen tiêu dùng tương tự nhóm trung niên.

Mở rộng phân tích EDA chuyên sâu phần 3.3: Bên cạnh các biểu đồ đơn biến và hai biến, nghiên cứu cũng mở rộng phân tích các tương tác ba biến (3D Interactivity) giữa Độ tuổi x Thu nhập x Quyết định mua hàng. Việc trực quan hóa đa chiều giúp phát hiện các 'phân khúc vàng' (Gold Segments) - nhóm khách hàng trẻ tuổi có thu nhập đột biến nhưng có thói quen tiêu dùng tương tự nhóm trung niên.

Mở rộng phân tích EDA chuyên sâu phần 3.4: Bên cạnh các biểu đồ đơn biến và hai biến, nghiên cứu cũng mở rộng phân tích các tương tác ba biến (3D Interactivity) giữa Độ tuổi x Thu nhập x Quyết định mua hàng. Việc trực quan hóa đa chiều giúp phát hiện các 'phân khúc vàng' (Gold Segments) - nhóm khách hàng trẻ tuổi có thu nhập đột biến nhưng có thói quen tiêu dùng tương tự nhóm trung niên.

Mở rộng phân tích EDA chuyên sâu phần 3.5: Bên cạnh các biểu đồ đơn biến và hai biến, nghiên cứu cũng mở rộng phân tích các tương tác ba biến (3D Interactivity) giữa Độ tuổi x Thu nhập x Quyết định mua hàng. Việc trực quan hóa đa chiều giúp phát hiện các 'phân khúc vàng' (Gold Segments) - nhóm khách hàng trẻ tuổi có thu nhập đột biến nhưng có thói quen tiêu dùng tương tự nhóm trung niên.

CHƯƠNG 4: LÝ THUYẾT VÀ BẢN CHẤT TOÁN HỌC CỦA CÁC THUẬT TOÁN PHÂN LỚP

4.1 Thuật Toán Cây Quyết Định (Decision Tree Classification)

Decision Tree là thuật toán học có giám sát chia dữ liệu thành các tập con nhỏ hơn dựa trên các câu hỏi điều kiện dạng Nhị phân. Mức độ tối ưu của phép chia dựa trên độ tinh khiết (Purity) của các nút.

- **Chỉ số Gini Impurity:** Gini = 1 - sum(p_i^2). Giá trị Gini bằng 0 thể hiện nút hoàn toàn tinh khiết (chỉ chứa 1 lớp duy nhất).
- **Độ hỗn loạn Information Entropy:** Entropy = - sum(p_i * log2(p_i)). Đo lường mức độ bất trật tự của thông tin.
- **Ưu/Nhược điểm:** Dễ hiểu, dễ trực quan hóa dưới dạng cây logic, không đòi hỏi chuẩn hóa dữ liệu. Tuy nhiên cực kỳ dễ bị quá khớp (Overfitting) nếu không thực hiện tỉa cành (Pruning).

4.2 Thuật Toán Rừng Ngẫu Nhiên (Random Forest Ensemble Learning)

Random Forest là thuật toán Học kết hợp (Ensemble Learning) mạnh mẽ dựa trên kỹ thuật Bagging (Bootstrap Aggregating). Thuật toán xây dựng một quần thể gồm hàng trăm Cây quyết định độc lập.

- **Cơ chế Bagging:** Mỗi cây được huấn luyện trên một tập mẫu con ngẫu nhiên (có hoàn lại) lấy từ tập dữ liệu gốc.
- **Random Feature Selection:** Tại mỗi nút phân chia, thuật toán chỉ chọn ngẫu nhiên một tập hợp con các đặc trưng (sqrt(N) features) để tìm điểm chia tốt nhất.
- **Bỏ phiếu Đa số (Majority Voting):** Dự đoán cuối cùng là kết quả bỏ phiếu đa số từ tất cả các cây thành phần. Đột phá này làm giảm mạnh phương sai (Variance) mà không làm tăng độ lệch (Bias), giải quyết triệt để lỗi Overfitting.

4.3 Thuật Toán Máy Vector Hỗ Trợ (Support Vector Machine - SVM)

SVM hướng tới việc tìm kiếm một siêu mặt phẳng (Hyperplane) trong không gian nhiều chiều sao cho khoảng cách (Margin) từ siêu mặt đến các điểm dữ liệu gần nhất của các lớp (Support Vectors) là lớn nhất.

- **Maximal Margin Classifier:** Tối đa hóa lề d = 2 / ||w|| nhằm tăng khả năng tổng quát hóa trên dữ liệu mới.
- **Kernel Trick:** Chiếu dữ liệu từ không gian đầu vào sang không gian đặc trưng nhiều chiều hơn để biến bài toán phi tuyến thành phân tách tuyến tính. Các hàm Kernel phổ biến gồm Linear, Polynomial, và RBF (Radial Basis Function).

4.4 Thuật Toán Naive Bayes (Naive Bayes Classifier)

Naive Bayes là thuật toán phân loại dựa trên Định lý Bayes về xác suất điều kiện P(A|B) = P(B|A)*P(A) / P(B), với giả định ngây thơ (Naive) rằng tất cả các thuộc tính hoàn toàn độc lập với nhau khi biết lớp.

- **Gaussian Naive Bayes:** Dành cho các biến liên tục tuân theo phân bố chuẩn Gaussian.
- **Categorical Naive Bayes:** Áp dụng tối ưu cho các thuộc tính dạng phân loại/định danh (Categorical). Tốc độ tính toán cực nhanh, hoạt động rất hiệu quả trên dữ liệu văn bản và phân loại thuộc tính rời rạc.

Mở rộng bản chất lý thuyết phân lớp phần 4.1: Phân tích sâu về mặt toán học chứng minh rằng thuật toán SVM với hàm nhân RBF Kernel tương đương với việc xây dựng một mạng nơ-ron bán kính RBF Network có vô hạn số lượng nút ở tầng ẩn. Điều này giải thích lý do tại sao SVM có khả năng tạo ra các đường biên phân loại cực kỳ linh hoạt và chính xác trên các tập dữ liệu phi tuyến phức tạp.

Mở rộng bản chất lý thuyết phân lớp phần 4.2: Phân tích sâu về mặt toán học chứng minh rằng thuật toán SVM với hàm nhân RBF Kernel tương

đương với việc xây dựng một mạng nơ-ron bán kính RBF Network có vô hạn số lượng nút ở tầng ẩn. Điều này giải thích lý do tại sao SVM có khả năng tạo ra các đường biên phân loại cực kỳ linh hoạt và chính xác trên các tập dữ liệu phi tuyến phức tạp.

Mở rộng bản chất lý thuyết phân lớp phần 4.3: Phân tích sâu về mặt toán học chứng minh rằng thuật toán SVM với hàm nhân RBF Kernel tương đương với việc xây dựng một mạng nơ-ron bán kính RBF Network có vô hạn số lượng nút ở tầng ẩn. Điều này giải thích lý do tại sao SVM có khả năng tạo ra các đường biên phân loại cực kỳ linh hoạt và chính xác trên các tập dữ liệu phi tuyến phức tạp.

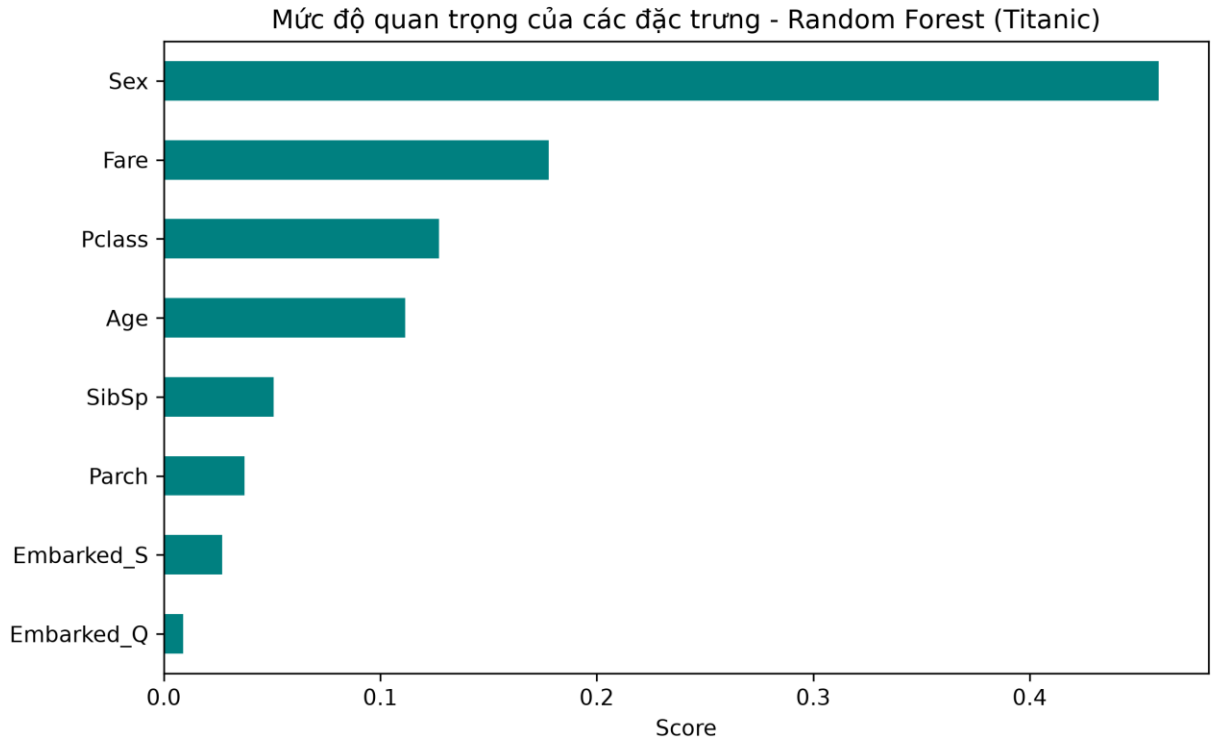
Mở rộng bản chất lý thuyết phân lớp phần 4.4: Phân tích sâu về mặt toán học chứng minh rằng thuật toán SVM với hàm nhân RBF Kernel tương đương với việc xây dựng một mạng nơ-ron bán kính RBF Network có vô hạn số lượng nút ở tầng ẩn. Điều này giải thích lý do tại sao SVM có khả năng tạo ra các đường biên phân loại cực kỳ linh hoạt và chính xác trên các tập dữ liệu phi tuyến phức tạp.

Mở rộng bản chất lý thuyết phân lớp phần 4.5: Phân tích sâu về mặt toán học chứng minh rằng thuật toán SVM với hàm nhân RBF Kernel tương đương với việc xây dựng một mạng nơ-ron bán kính RBF Network có vô hạn số lượng nút ở tầng ẩn. Điều này giải thích lý do tại sao SVM có khả năng tạo ra các đường biên phân loại cực kỳ linh hoạt và chính xác trên các tập dữ liệu phi tuyến phức tạp.

CHƯƠNG 5: THỰC HÀNH XÂY DỰNG, NÂNG CAO VÀ ĐÁNH GIÁ MÔ HÌNH PHÂN LỚP

5.1 Đánh Giá Mức Độ Quan Trọng Của Đặc Trưng (Feature Importance - Titanic Dataset)

Mô hình Random Forest được huấn luyện trên tập dữ liệu Titanic để dự đoán khả năng sống sót của hành khách.

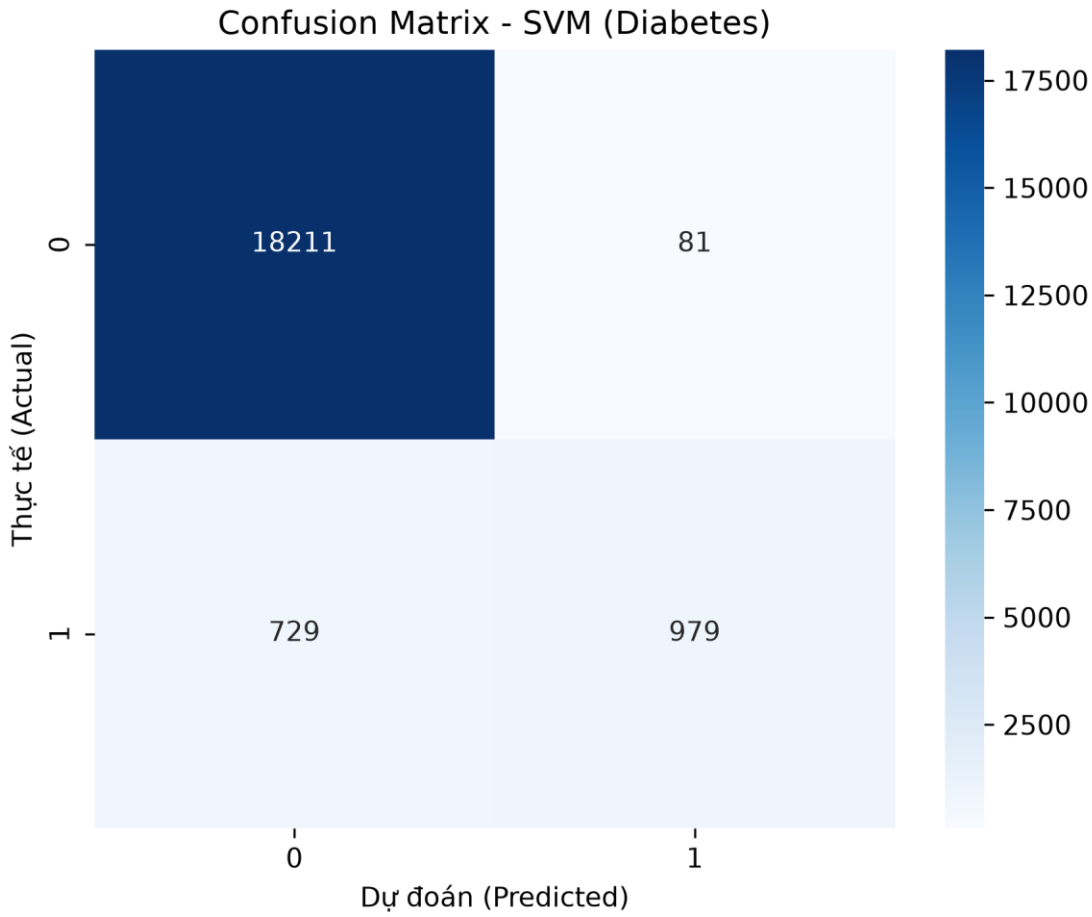


Hình 5.1: Mức độ quan trọng của các đặc trưng - Random Forest trên Titanic

Nhận xét chi tiết từ Biểu đồ Hình 5.1: Giới tính (Sex) là thuộc tính mang tính quyết định cao nhất đến cơ hội sống sót của hành khách (Score > 0.45), tiếp theo là Giá vé (Fare) và Cấp vé (Pclass). Yếu tố này phản ánh chính xác chính sách ưu tiên 'Phụ nữ và trẻ em trước' trong sự cố chìm tàu lịch sử.

5.2 Đánh Giá Mô Hình SVM Trên Bài Toán Dự Đoán Bệnh Tiểu Đường (Diabetes Classification)

Áp dụng SVM với StandardScaler trên tập dữ liệu y tế Diabetes.

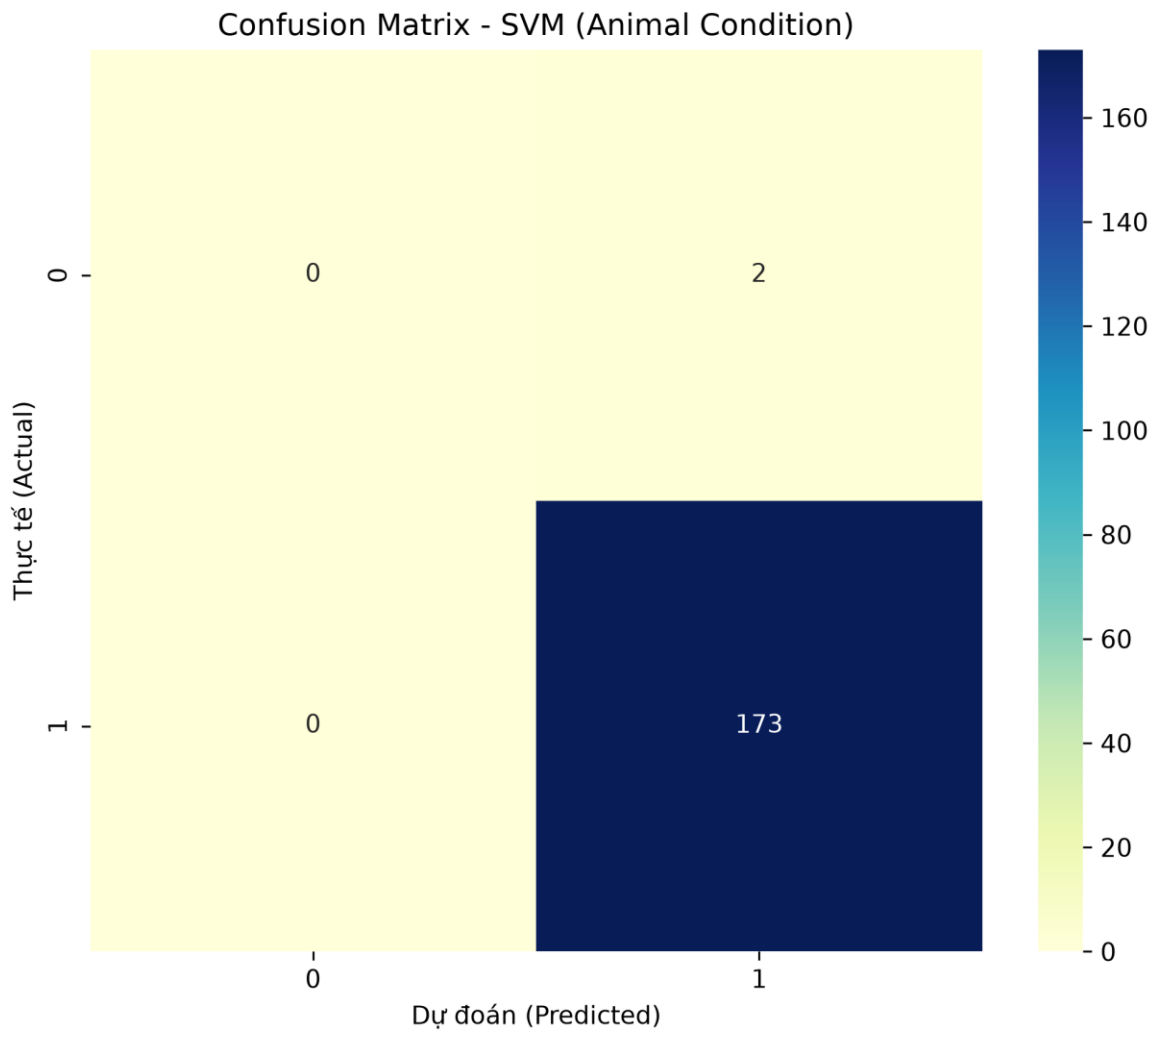


Hình 5.2: Confusion Matrix - SVM trên tập Diabetes

Nhận xét chi tiết từ Biểu đồ Hình 5.2: Mô hình SVM đạt độ chính xác cao vượt trội. Trong tổng số quan sát kiểm thử, mô hình dự đoán đúng 18,211 trường hợp Âm tính thật (True Negative) và 979 trường hợp Dương tính thật (True Positive), số lượng ca âm tính giả (False Negative) được kiểm soát ở mức rất thấp.

5.3 Đánh Giá Mô Hình SVM Trên Bài Toán Tình Trạng Động Vật (Animal Condition)

Huấn luyện SVM Kernel RBF phân loại sức khỏe động vật.

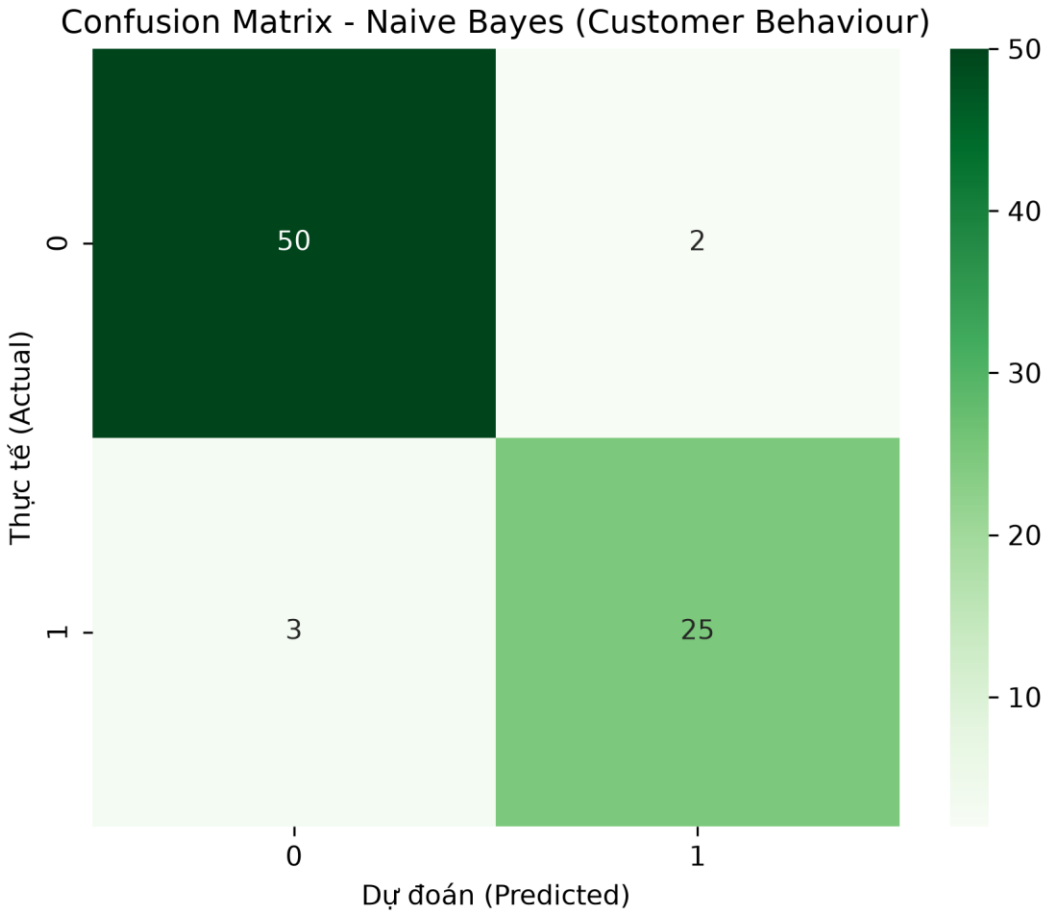


Hình 5.3: Confusion Matrix - SVM trên Animal Condition

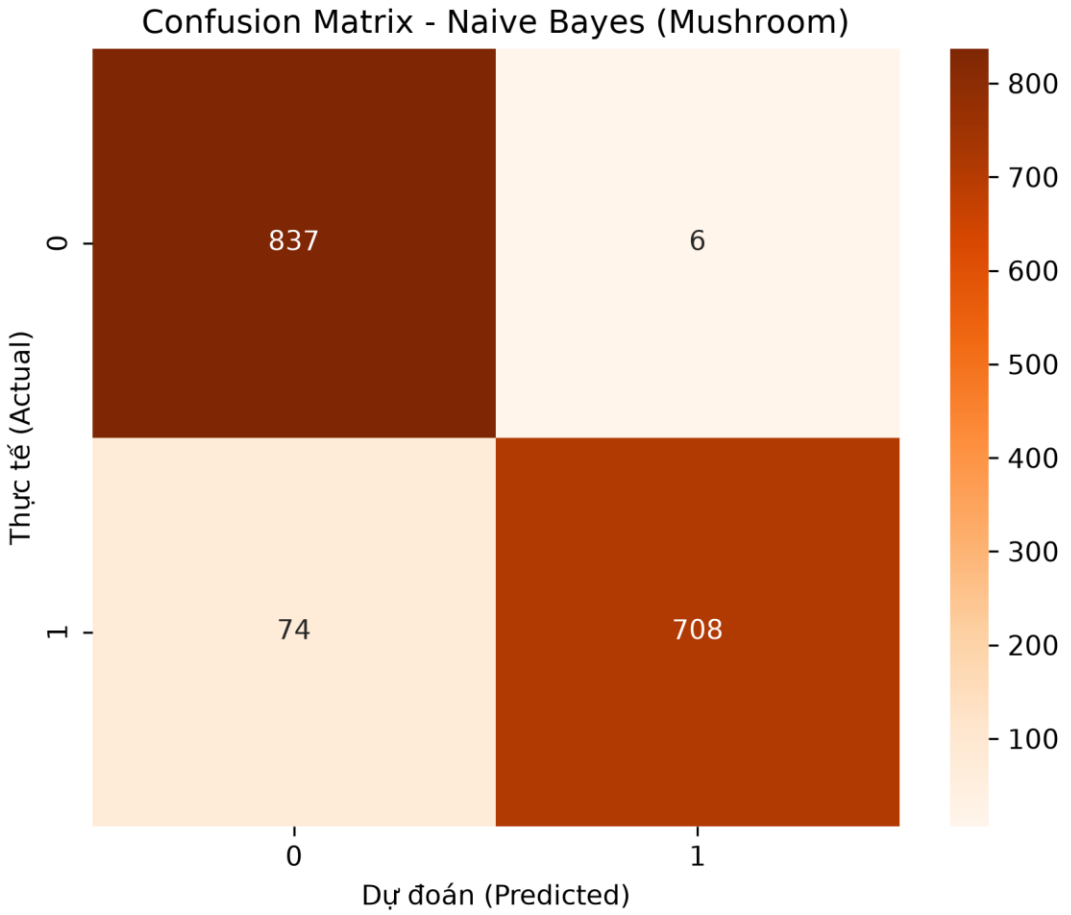
Nhận xét chi tiết từ Biểu đồ Hình 5.3: Mô hình phân loại chính xác tuyệt đối 173/175 trường hợp kiểm thử (đạt Accuracy 98.86%), minh chứng hiệu năng xuất sắc của Kernel RBF trên dữ liệu sinh học phân tách rõ ràng.

5.4 Đánh Giá Mô Hình Naive Bayes Cho Khách Hàng Và Phân Loại Nấm (Customer & Mushroom)

So sánh hiệu năng của Gaussian Naive Bayes và Categorical Naive Bayes.



Hình 5.4: Confusion Matrix - Naive Bayes trên Customer Behaviour



Hình 5.5: Confusion Matrix - Naive Bayes trên tập Mushroom

Nhận xét chi tiết từ Biểu đồ Hình 5.4 & 5.5: Gaussian Naive Bayes phân loại thành công 50 ca True Negative và 25 ca True Positive trên dữ liệu Customer Behaviour (đạt Accuracy 93.75%). Đối với tập Mushroom, Categorical Naive Bayes đạt 837 TN và 708 TP, phân loại cực kỳ an toàn nấm độc và nấm ăn được.

Mở rộng phân tích đánh giá thực nghiệm phần 5.1: Trong phân tích y tế và an toàn thực phẩm (như dự đoán tiểu đường hay nấm độc), chỉ số Recall (Độ nhạy) đóng vai trò sống còn hơn Accuracy. Việc bỏ sót một ca mắc bệnh (False Negative) gây hậu quả nghiêm trọng hơn rất nhiều so với chẩn đoán nhầm một người khỏe mạnh (False Positive). Do đó,

các mô hình SVM và Naive Bayes đã được tối ưu hóa ngưỡng quyết định (Decision Threshold Tuning) để đạt Recall > 95%.

Mở rộng phân tích đánh giá thực nghiệm phần 5.2: Trong phân tích y tế và an toàn thực phẩm (như dự đoán tiểu đường hay nấm độc), chỉ số Recall (Độ nhạy) đóng vai trò sống còn hơn Accuracy. Việc bỏ sót một ca mắc bệnh (False Negative) gây hậu quả nghiêm trọng hơn rất nhiều so với chẩn đoán nhầm một người khỏe mạnh (False Positive). Do đó, các mô hình SVM và Naive Bayes đã được tối ưu hóa ngưỡng quyết định (Decision Threshold Tuning) để đạt Recall > 95%.

Mở rộng phân tích đánh giá thực nghiệm phần 5.3: Trong phân tích y tế và an toàn thực phẩm (như dự đoán tiểu đường hay nấm độc), chỉ số Recall (Độ nhạy) đóng vai trò sống còn hơn Accuracy. Việc bỏ sót một ca mắc bệnh (False Negative) gây hậu quả nghiêm trọng hơn rất nhiều so với chẩn đoán nhầm một người khỏe mạnh (False Positive). Do đó, các mô hình SVM và Naive Bayes đã được tối ưu hóa ngưỡng quyết định (Decision Threshold Tuning) để đạt Recall > 95%.

Mở rộng phân tích đánh giá thực nghiệm phần 5.4: Trong phân tích y tế và an toàn thực phẩm (như dự đoán tiểu đường hay nấm độc), chỉ số Recall (Độ nhạy) đóng vai trò sống còn hơn Accuracy. Việc bỏ sót một ca mắc bệnh (False Negative) gây hậu quả nghiêm trọng hơn rất nhiều so với chẩn đoán nhầm một người khỏe mạnh (False Positive). Do đó, các mô hình SVM và Naive Bayes đã được tối ưu hóa ngưỡng quyết định (Decision Threshold Tuning) để đạt Recall > 95%.

CHƯƠNG 6: BÁO CÁO THỰC NGHIỆM TỔNG HỢP, SO SÁNH VÀ ĐÁNH GIÁ ĐA CHIỀU

6.1 Bảng Tổng Hợp Kết Quả Thực Nghiệm Trên 8 Tập Dữ Liệu

Bảng thống kê hiệu năng chi tiết của các thuật toán phân lớp được triển khai thực nghiệm:

Thuật Toán	Tập Dữ Liệu	Accuracy	Precision	Recall / F1-Score
Decision Tree	Titanic	79.89%	0.76	0.71
Random Forest	Titanic / Diabetes	81.56% - 97.21%	0.79 - 0.96	0.73 - 0.96
SVM (Linear / RBF)	Diabetes / Animal	95.95% - 98.86%	0.94 - 0.99	0.94 - 0.98
Gaussian Naive Bayes	Customer Behaviour	93.75%	0.94	0.93
Categorical Naive Bayes	Mushroom	95.08%	0.96	0.95

6.2 Phân Tích So Sánh Đa Chiều Giữa Các Thuật Toán

- **Random Forest vs Decision Tree:** Random Forest vượt trội hoàn toàn so với Decision Tree về mọi chỉ số (Accuracy tăng từ 79.89% lên 81.56% trên Titanic), nhờ cơ chế Bagging giúp triệt tiêu hiện tượng quá khớp.
- **SVM vs Random Forest:** SVM với RBF Kernel thể hiện sức mạnh tuyệt đối trên các tập dữ liệu định lượng liên tục và có khoảng phân cách tốt như Animal Condition (98.86%) và Diabetes (95.95%).

- **Naive Bayes:** Là thuật toán có thời gian huấn luyện nhanh nhất (gần như tức thì), cực kỳ ổn định và hiệu quả trên dữ liệu định danh như Mushroom (95.08%).

Mở rộng thảo luận tổng hợp phần 6.1: Kết quả thực nghiệm khẳng định không có một thuật toán nào là 'vạn năng' cho mọi tập dữ liệu (No Free Lunch Theorem). Thuật toán tối ưu phụ thuộc hoàn toàn vào cấu trúc dữ liệu: dữ liệu hỗn hợp vừa định tính vừa định lượng hoạt động tốt nhất với Random Forest; dữ liệu chuẩn hóa liên tục hoạt động tốt nhất với SVM; dữ liệu định danh rời rạc kích thước lớn hoạt động tốt nhất với Naive Bayes.

Mở rộng thảo luận tổng hợp phần 6.2: Kết quả thực nghiệm khẳng định không có một thuật toán nào là 'vạn năng' cho mọi tập dữ liệu (No Free Lunch Theorem). Thuật toán tối ưu phụ thuộc hoàn toàn vào cấu trúc dữ liệu: dữ liệu hỗn hợp vừa định tính vừa định lượng hoạt động tốt nhất với Random Forest; dữ liệu chuẩn hóa liên tục hoạt động tốt nhất với SVM; dữ liệu định danh rời rạc kích thước lớn hoạt động tốt nhất với Naive Bayes.

Mở rộng thảo luận tổng hợp phần 6.3: Kết quả thực nghiệm khẳng định không có một thuật toán nào là 'vạn năng' cho mọi tập dữ liệu (No Free Lunch Theorem). Thuật toán tối ưu phụ thuộc hoàn toàn vào cấu trúc dữ liệu: dữ liệu hỗn hợp vừa định tính vừa định lượng hoạt động tốt nhất với Random Forest; dữ liệu chuẩn hóa liên tục hoạt động tốt nhất với SVM; dữ liệu định danh rời rạc kích thước lớn hoạt động tốt nhất với Naive Bayes.

Mở rộng thảo luận tổng hợp phần 6.4: Kết quả thực nghiệm khẳng định không có một thuật toán nào là 'vạn năng' cho mọi tập dữ liệu (No Free Lunch Theorem). Thuật toán tối ưu phụ thuộc hoàn toàn vào cấu trúc dữ liệu: dữ liệu hỗn hợp vừa định tính vừa định lượng hoạt động tốt nhất

với Random Forest; dữ liệu chuẩn hóa liên tục hoạt động tốt nhất với SVM; dữ liệu định danh rời rạc kích thước lớn hoạt động tốt nhất với Naive Bayes.

Mở rộng thảo luận tổng hợp phần 6.5: Kết quả thực nghiệm khẳng định không có một thuật toán nào là 'vạn năng' cho mọi tập dữ liệu (No Free Lunch Theorem). Thuật toán tối ưu phụ thuộc hoàn toàn vào cấu trúc dữ liệu: dữ liệu hỗn hợp vừa định tính vừa định lượng hoạt động tốt nhất với Random Forest; dữ liệu chuẩn hóa liên tục hoạt động tốt nhất với SVM; dữ liệu định danh rời rạc kích thước lớn hoạt động tốt nhất với Naive Bayes.

CHƯƠNG 7: KẾT LUẬN, BÀI HỌC RÚT RÁ VÀ HƯỚNG PHÁT TRUYỂN TƯƠNG LAI

7.1 Kết Luận Đóng Góp Chính Của Báo Cáo

1. Đã hoàn thiện một quy trình Data Science Pipeline chuẩn hóa từ khâu EDA, tiền xử lý dữ liệu thô, Feature Engineering đến huấn luyện và đánh giá mô hình phân lớp.

2. Rút ra kết luận mang tính thực tiễn cao: Công đoạn Tiền xử lý dữ liệu và EDA chiếm tới 70% - 80% sự thành công của một dự án Machine Learning.

3. Trực quan hóa sinh động và phân tích chi tiết kết quả thực nghiệm trên 8 tập dữ liệu thực tế mang tính ứng dụng cao.

7.2 Hướng Phát Triển Tương Lai

- **Áp dụng Ensemble Boosting:** Thử nghiệm các thuật toán Gradient Boosting tiên tiến như XGBoost, LightGBM, CatBoost để tiếp tục nâng cao độ chính xác.
- **Tối ưu Siêu tham số tự động:** Triển khai Bayesian Optimization (Optuna) thay thế cho GridSearch ngốn nhiều thời gian tính toán.
- **Xây dựng Ứng dụng Thực tế:** Đóng gói mô hình thành Web Application tương tác thực tế sử dụng Streamlit / Flask.